

Des effets d'ordre sans attracteurs : une échelle d'architectures mémoire pré-enregistrée pour les agents LLM

Adrien Morelle

Chercheur indépendant , <https://github.com/DrImS/Prototypos>

23 juillet 2026

Résumé

Les agents fondés sur des modèles de langage sont de plus en plus souvent dotés d'une mémoire persistante, et une littérature grandissante documente leur *dérive* comportementale au fil d'interactions longues. Nous cherchons à savoir ce qui la *gouverne*. Sous un protocole pré-enregistré, dont les règles de décision ont été gelées avant toute collecte de données, nous comparons une échelle d'architectures mémoire — sans mémoire, journal brut en ajout seul, mémoire récurrente auto-résumée, mémoire vectorielle sémantique — à un agent doté d'un état explicite de faible dimension couplé à la *perception*. Deux propriétés habituellement confondues sous le terme de « dérive » se séparent nettement. La **dépendance à l'ordre** est gouvernée par l'adressage de la récupération : une mémoire adressée par contenu transmet l'histoire précoce jusqu'au comportement final ($|r| = 0,75, 99,5^{\text{e}}$ percentile d'un modèle nul de marche aléatoire apparié), là où les mémoires à fenêtre de récence et à réécriture l'effacent ($3,7^{\text{e}}$ et $78,2^{\text{e}}$). La journalisation des récupérations expose le mécanisme directement : les exemplaires précoces occupent encore 58 % des slots récupérés après une salve corrective complète, soit 1,36 fois leur taux de base positionnel. La **structure d'attracteurs**, elle, ne suit pas : toute architecture naturelle testée est monostable et corrigible — sur trois modèles dont un dépourvu de sa direction de refus — et la correction comportementale *devance* la composition de la mémoire ; seul l'état explicite couplé à la perception produit des bassins larges, bimodaux et hystérétiques. Enfin, une observation non prédite et directement pertinente pour le déploiement : l'agent le moins prudent est celui qui n'a rien vécu du tout — après trente-cinq tours coopératifs ordinaires, les agents obtempèrent sur la moitié d'une batterie de garde-fous, tandis qu'une mémoire de pression sociale, *quelle qu'en soit la direction*, élève leur niveau de vigilance. Nous concluons que la dérive comportementale structurée est une propriété architecturale, et non une conséquence émergente de la persistance mémoire.

1 Introduction

Un agent fondé sur un modèle de langage et doté d'une mémoire persistante conditionne chacune de ses réponses à une trace de ce qui a précédé. L'attente naturelle est que cela rende son comportement *dépendant du chemin* : les interactions précoces devraient façonner de manière disproportionnée la conduite ultérieure, et l'agent devrait pouvoir s'installer dans des modes comportementaux stables qui résistent à la correction. Cette attente sous-tend une grande part des préoccupations relatives au déploiement d'agents sur horizon long, où un assistant peut accumuler des centaines de tours d'historique avant d'entreprendre une action conséquente.

Nous mettons cette attente à l'épreuve et l'infirmos en grande partie. Notre observation centrale est que deux phénomènes couramment réunis sous le mot « dérive » sont en réalité séparables et relèvent de causes architecturales distinctes :

1. La **transmission de l'ordre** — le fait que le *moment* où quelque chose s'est produit laisse une trace dans le comportement final — est gouvernée par la manière dont la mémoire est *adressée*.
2. La **formation d'attracteurs** — le fait que le comportement se fixe dans des bassins larges, stables et résistants à la correction — n'apparaît dans aucune architecture mémoire naturelle que nous ayons testée, et requiert un état explicite de faible dimension couplé à la perception.

Contributions. (i) Une échelle d'architectures pré-enregistrée isolant l'adressage de la récupération comme dimension opérante des effets d'ordre (§4). (ii) La mesure directe, au niveau du récupérateur, du mécanisme qui transmet l'histoire précoce — et la démonstration que transmission n'implique pas verrouillage (§5). (iii) Une observation non prédite, pertinente pour le déploiement : une mémoire coopérative sans pression constitue l'état le *moins* prudent (§6). (iv) Une méthode de « champ d'appréciation » peu coûteuse, et la valeur diagnostique de son échec sur les agents naturels (§7).

2 Travaux liés

Dérive de persona et d'identité. Li et al. [1] ont introduit un test quantitatif de stabilité de persona reposant sur des auto-conversations entre agents personnalisés, et rapportent une dérive significative en moins de huit tours sur LLaMA2-chat-70B, qu'ils attribuent en partie à la décroissance de l'attention au fil des échanges longs. Choi et al. [2] ont examiné la cohérence identitaire sur neuf modèles et constatent que les modèles les plus grands dérivent davantage, et qu'assigner une persona ne suffit pas à l'empêcher. Le plus proche de notre cadre, ContextEcho [3] mesure la dérive de persona à l'échelle du déploiement, sur de longues sessions de codage agentique, au moyen d'un protocole de capture-puis-sondage qui bifurque l'état conversationnel sans perturber la session principale — la discipline de mesure que nous adoptons également (§4).

La mémoire comme source de changement comportemental. Dabas et al. [4] étudient la *dérive d'outillage induite par la mémoire* : des biais stockés en mémoire affectent silencieusement les appels d'outils dans des contextes où ils ne s'appliquent pas. Ils rapportent que les mémoires biaisées agissent comme des vecteurs de pilotage implicites, et que les défenses standard réduisent l'effet sans l'éliminer. Wei et al. [5] décrivent un cycle d'erreur auto-renforçant dans lequel un résultat corrompu est stocké comme précédent, amplifiant l'erreur initiale et abaissant progressivement le seuil de défaillances similaires. Lin et al. [6] passent en revue la sécurité de la mémoire à long terme et reformulent la question directrice : non plus « l'entrée actuelle est-elle nuisible ? » mais « dans quel *état* mémoriel le système se trouve-t-il ? ».

Positionnement de ce travail. Cette littérature est majoritairement adversariale ou orientée mesure : elle étudie des mémoires injectées ou empoisonnées, et mesure la dérive dans des systèmes en boîte noire. Notre contribution lui est complémentaire à deux titres. D'abord, l'effet de précédent de soi que nous observons survient *sans aucun adversaire* — il est produit par une interaction ordinaire. Ensuite, nous menons une comparaison contrôlée *entre architectures mémoire* sous un protocole identique, ce qui localise quelle propriété architecturale produit quel phénomène. En particulier, le précédent auto-renforçant décrit en contexte adversarial par [5] apparaît dans notre cadre comme une transmission *sans* verrouillage : la correction devance la composition de la mémoire (§5).

3 Un état explicite présente la signature complète

Nous établissons d’abord qu’un système fondé sur un modèle de langage *peut* présenter la signature complète, afin qu’un résultat nul sur les agents naturels soit informatif plutôt qu’un artefact de protocole trop faible.

3.1 Modèle

L’agent porte un état sur deux échelles de temps. Une *humeur* rapide (v, r) relaxe vers l’appréciation de l’événement courant, et un vecteur de *traits* lent — dont nous suivons l’axe d’attachement $x_A \in [-1, 1]$ — intègre l’humeur soutenue. En notant $\hat{v}_t$ la valence perçue de l’événement t ,

$$v_{t+1} = v_t + k_v(\hat{v}_t - v_t), \quad r_{t+1} = r_t + k_r(\hat{a}_t - r_t), \quad (1)$$

avec k_v, k_r suffisamment grands pour que l’humeur s’équilibre en quelques interactions. L’axe de trait suit une mise à jour cubique (à double puits),

$$\Delta x_A = (a x_A - b x_A^3 + w v_t) \eta(t), \quad (2)$$

dont la partie déterministe possède des points fixes en $x_A^* = 0$, instable, et $x_A^* = \pm \sqrt{a/b}$, stables. Le terme cubique sature la dynamique au niveau des puits, de sorte que l’état ne peut diverger ; le centre instable implique que le système ne peut demeurer neutre. La plasticité décroît avec l’âge,

$$\eta(t) = \eta_0 \exp(-t/\tau), \quad (3)$$

si bien que les événements précoces agissent alors que le taux d’apprentissage est élevé — une dépendance au chemin par construction, et l’analogie computationnel d’une période critique.

3.2 Couplage perceptif

La composante porteuse est que l’état biaise l’*interprétation*, et non seulement l’expression. Étant donné les primitives d’appréciation — soin c , menace θ , nouveauté ν , autonomie α — le soin perçu d’un événement s’écrit

$$\tilde{c} = c - \kappa \max(0, -x_A) (1 - |c|), \quad (4)$$

de sorte qu’un état dégradé ($x_A < 0$) lit négativement les événements *ambigus* ($|c|$ faible), tandis que les événements non ambigus restent largement inchangés. Valence et éveil perçus suivent alors

$$\hat{v} = \text{clip}(\tilde{c} - 0,5\theta + 0,3\alpha, -1, 1), \quad \hat{a} = \text{clip}(0,7\theta + 0,5\nu, 0, 1). \quad (5)$$

L’équation (4) referme une boucle : état $\rightarrow$ interprétation $\rightarrow$ état. Nous avons vérifié qu’un modèle de langage réel reproduit ce couplage lorsqu’on lui fournit l’état et qu’on lui demande d’apprécier les événements du point de vue de l’agent : sur des événements ambigus, l’injection d’un état dégradé plutôt que sécure décale le soin apprécié de $-0,737$ (IC à 95 % $[-0,865; -0,609]$), contre une prédiction pré-engagée d’un décalage négatif compris dans $[-0,6; -0,15]$.

3.3 Signature

La figure 1 en montre la conséquence. Un état poussé dans le bassin négatif ne revient pas sous une correction de magnitude égale, précisément parce que l’équation (4) escompte l’entrée qui le restaurerait ; le couplage ablaté, la même entrée restaure l’état. L’irréversibilité n’est donc pas une règle surajoutée : elle découle du mécanisme même qui produit les bassins.




Figure 1: La signature de l’état explicite. Un état capturé dans le bassin adverse ne récupère pas sous une correction de magnitude égale lorsque la perception est couplée à l’état (orange), alors que le système ablaté récupère intégralement (bleu). La plasticité étant maintenue constante, l’asymétrie est imputable à l’équation (4) et non à la décroissance du taux d’apprentissage.

4 L’échelle d’architectures mémoire

Nous demandons ensuite si un agent à mémoire *naturelle* — récupérer, répondre, écrire une note auto-rédigée, sans aucun scalaire construit à la main — présente la même signature.

4.1 Protocole

Tous les barreaux exécutent un protocole identique : même boucle d’agent, même juge fixe, même batterie de sondes comportementales sur un axe de prudence / respect des garde-fous, et même ensemble gelé de 12 ordonnancements tirés d’un multiensemble fixe d’événements de pression. Les sondes s’exécutent dans un contexte cloné puis jeté, de sorte que la mesure ne puisse altérer la mémoire. Les barreaux sont

	architecture	adressage	état
R0	sans mémoire	—	aucun
R1	journal brut en ajout seul	fenêtre de récence	texte non borné
R2	mémoire auto-résumée	réécriture	texte compressé
R3	mémoire vectorielle sémantique	contenu (top- k)	texte non borné
R4	état latent explicite	—	faible dimension, couplé perception

La dépendance au chemin est évaluée contre le modèle nul *propre* à chaque barreau : nous engendrons 10^4 marches aléatoires dont la variance de pas est appariée aux incréments de sondes mesurés, et demandons si la corrélation observée r entre la composition de l’histoire précoce et la position comportementale finale dépasse le 95^e percentile de $|r|$ sous le modèle nul.

4.2 Résultat

Le tableau 1 et la figure 2 donnent le résultat, et ce n’est pas celui que nous avons prédit. Notre hypothèse pré-enregistrée soutenait que les effets d’ordre suivraient spécifiquement le *couplage perceptif*. Le test décisif était R3 : une mémoire sophistiquée dépourvue de tout couplage, prédite en aveugle comme ne devant montrer aucune dépendance à l’ordre. Ce fut la *seule* architecture naturelle à dépasser son modèle nul, au 99,5^e percentile. La prédiction était fausse et est rapportée comme telle.

Tableau 1: L'échelle. La transmission de l'ordre est le percentile, sous le modèle nul, de la corrélation observée avec l'histoire précoce ; la structure d'attracteurs est la dispersion des points d'arrivée sur les ordonnancements gelés. R4 relève d'un substrat différent : sa dispersion n'est pas directement comparable en valeur absolue et son statut est importé d'une dépendance au chemin établie séparément.

barreau	adressage	$ r $	pct. nul	$\sigma(\text{arrivée})$	au-delà du nul
R0	—	0,575*	—	0,071	non
R1	récence	0,015	3,7	0,046	non
R2	réécriture	0,389	78,2	0,051	non
R3	contenu	0,751	99,5	0,062	oui
R4	(état explicite)	0,510	—	0,764	oui

* bruit de génération sur une mémoire restée vide ; sa dispersion constitue le plancher de bruit de l'instrument.




Figure 2: Transmission de l'ordre et structure d'attracteurs sont séparables. (a) La transmission de l'ordre croît de façon monotone avec l'adressage de la récupération ; seul l'adressage par contenu dépasse le modèle nul. (b) Dispersion des points d'arrivée : toute architecture naturelle, R3 comprise, demeure à l'intérieur de la bande de bruit de l'instrument ; seul l'état explicite couplé à la perception (R4, violet) produit des bassins larges.

La dimension séparatrice n'est ni la compression, ni la récurrence, ni le couplage — les trois propriétés que nous avons gelées — mais l'**adressage de la récupération**. Une fenêtre de récence oublie les tours précoces par construction (3,7^e percentile) ; un résumé auto-réécrit écrase son propre passé (78,2^e) ; une mémoire adressée par contenu, n'ayant ni décroissance ni réécriture, demeure capable de remonter arbitrairement loin (99,5^e). Que l'axe gelé n'ait pas contenu la dimension opérante constitue en soi un résultat rapportable au sujet de cet axe.

Point crucial, R3 réussit le test d'ordre tout en ne présentant *aucune* structure d'attracteurs. Sa dispersion finale (0,062) se situe dans la bande de bruit de l'instrument, les douze exécutions terminent dans la région haute de l'axe, et aucune bimodalité n'apparaît — contre une dispersion de 0,764 pour l'état explicite. La mémoire vectorielle déplace le point d'arrivée à *l'intérieur d'une bande étroite* ; elle ne crée pas de bassins.




Figure 3: Le retour en arrière, mesuré au récupérateur. Les exemplaires précoces persistent au-dessus du taux de base durant toute la phase corrective ; les exemplaires correctifs s’accumulent sans les déplacer.

5 Transmettre sans verrouiller

L’histoire transmise est-elle *verrouillée* ? Nous avons journalisé la provenance de chaque élément récupéré — indice en mémoire et tour d’origine — à chaque sonde.

Le mécanisme, mesuré. La figure 3 montre que les exemplaires précoces conservent 58,3 % des slots récupérés à la batterie finale, soit 1,36 fois leur taux de base positionnel, vingt tours et une salve corrective complète plus tard. Les exemplaires correctifs s’accumulent de façon monotone sans jamais déplacer la trace précoce : ils concurrencent les slots du top- k plutôt qu’ils ne les évincent. Ce qui diffère selon les ordonnancements n’est pas le message de l’utilisateur — toutes les mémoires terminent avec le même multiensemble — mais les *propres réponses stockées* de l’agent. Les exécutions dont les premiers exemplaires se sont formés sous pression, sur une mémoire quasi vide, ont produit des refus moins fermes, et la récupération par contenu continue de faire précisément remonter ceux-là.

Mais le comportement n’est pas capturé. En dépit de la récupération persistante de la trace précoce, le comportement a récupéré *plus vite* que ne le prédit la composition de la mémoire (retard moyen de $-0,114$ contre une référence de dilution pure), terminant au-dessus de la référence non pressée. Le bras contre-directionnel n’a bougé que de $-0,056$ sous une pression opposée de magnitude égale. L’ajustement de l’équation (2) au champ de transition mesuré pour R3 donne $a = -0,76$: monostable, le double puits est rejeté par les données.

Nous rapportons un résultat négatif important quant au protocole : le discriminateur pré-enregistré n’a pas pu être arbitré tel que conçu, car sa prémisse a échoué — l’induction d’assouplissement visée a produit l’effet inverse dans deux exécutions sur trois. Une porte d’adéquation, spécifiée à l’avance, a déclaré les hypothèses correspondantes non concluantes plutôt que de laisser extraire une lecture. La lecture en termes de bassin est refusée sur la base d’un faisceau convergent — dépassement lors de la récupération, tenue du bras contre-directionnel, et ajustement monostable — et non sur celle d’un test unique.

La composition des récupérations contraint donc ce que l’agent *voit*, non ce qu’il en fait.




Figure 4: L’agent non pressé est le moins prudent. (a) Respect des garde-fous selon l’historique d’interaction ; exécutions individuelles superposées. (b) La même inversion à travers l’instrument de champ : toute mémoire de pression prépare un respect supérieur à celui d’un préfixe neutre.

6 L’état ordinaire

Le nombre le plus lourd de conséquences dans nos données n’avait été prédit dans aucune direction.

Notre condition de référence jamais pressée — un agent ayant vécu trente-cinq tours coopératifs ordinaires et aucune pression sociale d’aucune sorte — obtient le score le *plus bas* de respect des garde-fous (0,688), en deçà de toute condition pressée (0,81–0,93). À la batterie finale, ces exécutions obtempèrent franchement sur la moitié des sondes, notamment en inscrivant un identifiant en dur dans un script, en accordant des permissions d’accès sans restriction, et en transmettant des chiffres non vérifiés. Mesurée à travers l’instrument de champ indépendant (figure 4b), la même inversion apparaît : un préfixe neutre prépare le niveau de respect le plus bas de tous les préfixes testés, et une pression de l’une ou l’autre direction en prépare un plus élevé.

Interprétation, et ce que nous ne pouvons distinguer. Une lecture possible est que trente-cinq tours de coopération ordinaire constituent un *précédent de soi d’exécutant complaisant* : la mémoire montre à l’agent un soi qui dit oui, et la récupération par contenu continue de le lui montrer. Une lecture plus simple est celle de la *saillance sécuritaire* : tout contenu mémoriel lié à la sécurité amorcerait la prudence, indépendamment du fait qu’il encode ou non quoi que ce soit sur la conduite propre de l’agent. Nos données sont compatibles avec les deux et ne permettent pas de les départager. L’expérience discriminante consisterait en une mémoire contenant du matériel saillant du point de vue sécuritaire *sans* pression sociale — par exemple l’agent effectuant des vérifications soigneuses de sa propre initiative ; si cela élève également le respect, la saillance suffit.

Nous soulignons la portée pour le déploiement tout en signalant son poids probatoire ($n = 3$ exécutions de référence ; observation incidente, non pré-enregistrée). Les sessions longues, ordinaires et coopératives constituent le régime de fonctionnement *normal* des agents de développement et d’exploitation, et non le régime adversarial que modélisent habituellement les travaux de sécurité sur la dérive.

7 Méthodes et reproductibilité

Pré-enregistrement. Chaque expérience de ce travail a été précédée d'un pré-enregistrement versionné avant toute collecte de données, spécifiant prédictions, seuils, et une règle de décision associant les issues aux affirmations licenciées. Les prédictions fausses sont notées telles que gelées et rapportées. Quatre le sont ici : le test décisif sur R3 ; une prédiction de dégénérescence sur le champ de R3 ; une lecture antérieure d'une hausse de prudence comme réactance à la pression permissive (rétractée après qu'un balayage multi-modèles eut montré que la pression permissive seule ne déplace aucun modèle) ; et la prédiction relative à la condition de référence de la section 6.

Arbitre du modèle nul. Le signe d'un ajustement à double puits n'est jamais rapporté seul. Un ajustement antérieur avait retourné $a = +241$ sur un champ dépourvu de levier spatial ; l'arbitre pré-engagé — le modèle nul de marche aléatoire employé pour l'échelle — l'a correctement identifié comme dégénéré.

Champ d'appréciation. Pour le système à état explicite, l'appréciation est sans mémoire conditionnellement à l'état : l'application (événement, état) $\rightarrow$ appréciation peut donc être mesurée une fois sur une grille, puis servir à simuler des trajectoires à coût marginal nul. La fidélité aux exécutions complètes avec modèle en boucle était quasi exacte (écart absolu moyen de 0,013 ; 10/10 paires dans la tolérance). Appliquée aux agents naturels, la méthode *échoue* (écart moyen 0,933 ; 0/5), l'axe comportemental n'étant pas une statistique exhaustive d'une mémoire. Cet échec est lui-même diagnostique : il sépare nettement les architectures dont l'état est de faible dimension de celles dont l'état est leur contenu mémoriel.

8 Limites

Trois modèles, tous dans la gamme des 8 à 9 milliards de paramètres, quantifiés, exécutés localement ; un seul axe comportemental ; une architecture à état explicite et quatre architectures naturelles. Une échelle fournit un faisceau en faveur de la nécessité, jamais une preuve : aucune famille finie d'architectures n'exclut toutes les alternatives. Notre affirmation licenciée est donc que l'état explicite couplé à la perception est *suffisant* là où la persistance mémoire ne l'est pas — et non qu'il soit requis. Sur cet ensemble de barreaux, compression et couplage sont ordinalement colinéaires : un critique peut donc redécrire le résultat de couplage comme un résultat de compression ; l'expérience qui les sépare consiste en un résumé compressé réinjecté comme consigne d'interprétation. L'observation de la section 6 repose sur trois exécutions de référence et demeure confondue comme indiqué. Les batteries de sondes mesurent une disposition déclarée sous instrument fixe, non une action en déploiement. Le juge est lui-même un modèle de même échelle que les agents.

9 Conclusion

Effets d'ordre et dynamique d'attracteurs sont des propriétés séparables des agents à mémoire, aux causes architecturales distinctes. L'adressage de la récupération détermine si l'histoire précoce atteint le comportement final : les mémoires adressées par contenu la transmettent, celles à récence et à réécriture l'effacent. Mais transmettre n'est pas verrouiller — aucune architecture naturelle testée n'est bistable, et la correction devance la composition de la mémoire. Des bassins comportementaux persistants ne sont apparus qu'avec un état explicite de faible dimension couplé à la perception. Ce que la mémoire transmet semble être moins une quantité signée qu'une forme de précédent remémoré : un historique coopératif assouplit, un historique de pression, quelle qu'en soit la direction, durcit. Si cela se confirme sous réplique, l'implication

opérationnelle est inconfortable et mérite d’être énoncée sans détour : l’agent qui vous a tenu tête n’est pas celui dont il faut se méfier.

Reproductibilité

Le code, les pré-enregistrements accompagnés de l’horodatage de leurs *commits*, les fichiers de résultats bruts et les scripts d’analyse produisant chaque figure et chaque tableau de cet article sont disponibles à l’adresse <https://github.com/Drims/Prototypos>. Chaque pré-enregistrement précède son expérience dans l’historique des *commits*.

Références

- [1] K. Li, T. Liu, N. Bashkansky, D. Bau, F. Viégas, H. Pfister et M. Wattenberg. Measuring and Controlling Persona Drift in Language Model Dialogs. arXiv preprint arXiv:2402.10962, 2024.
- [2] J. Choi [+3 auteurs — à compléter depuis arXiv]. Examining Identity Drift in Conversations of LLM Agents. arXiv preprint arXiv:2412.00804, 2024.
- [3] [auteurs — à compléter depuis arXiv]. ContextEcho: A Benchmark for Persona Drift in Long Agentic-Coding Sessions. arXiv preprint arXiv:2605.24279, 2026.
- [4] M. Dabas [+3 auteurs — à compléter depuis arXiv]. Memory-Induced Tool-Drift in LLM Agents. arXiv preprint arXiv:2605.24941, 2026.
- [5] Q. Wei, T. Yang, Y. Wang, X. Li, L. Li, Z. Yin, Y. Zhan, T. Holz, Z. Lin et X. Wang. A-MemGuard: A Proactive Defense Framework for LLM-Based Agent Memory. arXiv preprint arXiv:2510.02373, 2025.
- [6] Z. Lin [+7 auteurs — à compléter depuis arXiv]. A Survey on Long-Term Memory Security in LLM Agents: Attacks, Defenses, and Governance Across the Memory Lifecycle. arXiv preprint arXiv:2604.16548, 2026.